

PBL 모듈 #2 보고서

서울시 청년 비만의 데이터 기반 진단 및 군집형 정책 타겟팅

공공데이터에 6대 분석 기법을 교차 적용한 근거 기반 정책 설계

2025957072

강서운

2023320012 강성하

2025320036 이태엽

2023320004 호준수

I. 서론

1.1 문제 정의 - 왜 '청년' 비만인가

비만은 제2형 당뇨병·고혈압·이상지질혈증으로 이어지는 대사질환의 공통 상류(upstream) 위험인자다. 그중에서도 청년기(만 19~39세) 비만은 이후 수십 년에 걸친 만성질환 부담과 사회적 의료비용의 선행지표이므로, 동일한 예산을 투입했을 때 생애 전체 건강손실을 줄이는 효과가 가장 큰 구간이다. 본 분석에서 측정된 서울시 청년 비만율은 27.3%로, 청년 약 3.7명 중 1명이 비만(BMI 25 이상)에 해당한다.

본 프로젝트는 데이터 분석 컨설팅 기업 SM-DataLabs의 관점에서, 청년 비만을 개인의 의지 문제가 아니라 거주 지역의 구조적 환경 문제로 재정의한다. 즉 비만율은 개인 생활습관의 단순 총합이 아니라, 거주 자치구의 신체활동 인프라(체육시설)와 식이 환경(외식·배달 상권)에 의해 체계적으로 좌우된다는 가설을 검증하고, 이를 토대로 자치구별 맞춤 정책을 설계하는 것이 목표다.

1.2 분석 질문

① 청년 비만은 어떤 환경·행동 요인에 의해 결정되는가? ② 서울 25개 자치구는 어떤 정책 유형으로 군집화되는가? ③ 식별된 군집마다 비용 대비 효과가 가장 큰 처방은 무엇인가?

1.3 데이터 출처 및 신뢰성

세 개 도메인의 공공데이터를 통합하였다.

- 종속변수(청년 비만): 질병관리청 「지역사회건강조사(KCHS)」 2019~2025년 7개년 원시마이크로데이터에서 서울 거주 만 19~39세 추출.
- 신체활동 인프라(H2): 서울 열린데이터광장 「공공체육시설 통계(2011~2024)」 + 「등록·신고 체육시설 통계(2010~2024)」.
- 식이 환경(H1): 서울시 「상권분석서비스」의 점포(2021~2025)·추정매출(2021~2025) + 상권 영역 Shapefile.

1.4 방법론 — 6대 분석기법 교차 적용

가이드라인의 분석전략(문제 정의 → 군집 → 예측 → 분류 → 연관)에 정확히 대응하도록 6개 기법을 교차 적용하여, 6개 기법을 교차 적용하여, '4개 이상 기법 교차 활용'이라는 가이드라인 기준을 충분히 상회한다.

표 1. 가이드라인 분석전략과 적용 기법의 매핑

가이드라인 분석전략	적용 기법	분문
문제 정의	EDA·상관분석	IV
군집 분석(비/계층)	K-Means 군집	V
예측 모델링	OLS 선형회귀(개인 BMI)	VI
분류 모델링	로지스틱 회귀(비만 여부)	VII
예측·분류	의사결정트리·랜덤포레스트·뉴럴넷	VII
연관 분석	Association Rule(lift)	VII
예측 모델링(가설 검증)	자치구 수준 OLS	VIII

표 1. 가이드라인 분석 전략과 적용 기법의 매핑

II. 연구 가설

H1 (식이 환경): 배달친화 외식업이 밀집한 자치구일수록 청년 비만율이 높다(양의 상관). 배달친화 업종은 패스트푸드·치킨·분식으로 조작적으로 정의하였다.

H2 (신체활동 인프라): 체육시설이 많은 자치구일수록 청년 비만율이 낮다(음의 상관).

H3 (개인 행동): 흡연·고스트레스·수면부족은 개인의 비만 위험을 높이고, 이들 위험요인은 상호 동시발생(co-occurrence)한다.

III. 데이터 수집 및 전처리

3.1 표본 구축

KCHS 7개년에서 서울 거주자 160,434행을 병합하고 만 19~39세로 필터링하여 46,293행을 확보, 신체계측 이상치(BMI 10~60 밖) 672행 제거 후 최종 개인 45,621행, 자치구×연도 175행(25구×7년), 분석용 자치구 마스터 25행을 구축하였다. 청년 비만율은 27.3%, 평균 BMI는 23.19다.

3.2 변수 설계

- 종속변수: 개인 비만여부(BMI≥25), 자치구 비만율(%)
- 개인 행동변수: 걷기일수·수면시간·아침식사·스트레스·흡연·음주·우울
- 환경변수: 총체육시설수(H2), 배달친화 점포비중·청년 배달매출비중(H1)
- 통제변수: 연령·성별·연도

3.3 데이터 통합 과정의 주요 처리 내역

세 도메인의 원자료를 그대로 병합할 경우 분석이 불가능하여, 다음 6개 항목의 정합성 문제를 처리하였다.

1. 연도별 컬럼명 불일치 — KCHS는 2019~2021년 소문자, 2022년 이후 대문자 변수명을 사용해 매핑 사전으로 표준화하였다.
2. 결측 특수코드 — 99999·77·88·99 등 무응답·비해당 코드를 NaN으로 변환 후 처리하였다.
3. 상권→자치구 매핑 — 점포·매출 데이터에는 자치구 정보가 없고 상권코드만 존재하여, 상권 영역 Shapefile의 속성테이블(DBF)에서 1,650개 상권을 25개 자치구로 매핑하였다(매핑 실패 0행). 이 단계가 H1 검증의 전제였다.
4. 2025년 상권 영문 컬럼 — 2025년 자료만 영문 헤더로 제공되어 한글 스키마로 표준화하였다.
5. 체육시설 단일 결측 — 중구 2020년 민간시설 1셀이 미집계(-)였으며, 0이나 전체평균 대체 대신 자치구별 시계열 선행보간으로 메웠다.
6. 이상치 처리 (IQR 미적용)— IQR 절단은 정상 분포의 꼬리(실제 고도비만 청년)를 제거해 종속변수를 왜곡한다. 따라서 생물학적으로 불가능한 범위(BMI 10~60)만 제거하고 나머지는 보존하였다.

3.4 결측·연도창 정합성 진단

통합 패널(175행) 결측률은 비만지표 0%, 체육시설 14.3%(2025년 미공개), 상권 28.6%(2019~2020년 원자료 부재)였다. 미공개 구간을 무리하게 역추정하지 않고, 결과변수(비만)는 2019~2025년, 체육시설은 2019~2024년, 상권은 2021~2025년으로 분석 시점을 정합화하였다. 체육시설 2010~2024 전체평균 대비 2019~2024

평균의 자치구 순위상관은 $\rho=0.96$ 으로, 연도차선택이 결론에 미치는 영향은 미미함을 확인하였다(그림 2).




그림 1. 데이터 가용성 히트맵




그림 2. 체육시설 전처리 전후

IV. 탐색적 데이터 분석

4.1 비만을 추세

연도별 서울 청년 비만율은 2019년 26.8%에서 2024년 29.6%까지 상승했다가 2025년 27.7%로, 추세적으로 26~30% 구간에서 등락하며 뚜렷한 감소 신호는 보이지 않는다(그림 3-좌). 자치구 평균 비만율은 27.5%이며, 최고 도봉구(32.4%)와 최저 서초구(22.1%) 간 격차가 10.3%p에 달해 자치구 단위 개입의 여지가 크다.




그림 3 - [좌] 연도별 청년 비만율 추세 + [우] 비만율-환경요인 상관

4.2 환경요인 상관 진단

자치구 비만율과의 상관계수는 배달친화 점포비중 +0.637, 청년 배달매출비중 +0.507, 흡연율 +0.497로 식이·행동 요인이 강한 양의 상관을, 총체육시설수 -0.310으로 인프라가 음의 상관을 보였다(그림 3-우). 흥미롭게도 평균건기일수는 -0.003으로 비만율과 사실상 무상관이었다 — 이는 ‘운동을 더 하면 비만이 줄 것’이라는 직관과 배치되며, 신체활동 ‘행위’보다 식이 환경이 자치구 비만율을 더 강하게 규정함을 시사하는 1차 근거다. 마스터 변수 상관행렬(그림 4)에서도 환경변수 간 우려할 만한 다중공선성은 나타나지 않았다.




그림 4 -자치구 마스터 변수 상관행렬 히트맵 (다중공선성 사전 점검)

V. 군집 분석 — 자치구 정책 타겟 그룹화

정책 타겟팅을 위해 25개 자치구를 환경·행동 ‘동인’ 변수(건기·흡연율·체육시설·배달환경)로 K-Means 군집하였다. 순환논리를 차단하기 위해 종속변수(비만율)는 입력에서 제외하고, 군집 후 비만율 차이로 사후 검증하였다. 실루엣 계수는 $k=3$ 에서 0.279로 최대였다($k=2:0.263$, $k=4:0.274$, $k=5:0.264$). 도출된 3개 정책 그룹은 다음과 같다(표 2, 그림 5).

표 2. 군집별 프로파일 (K-Means, $k=3$)

정책 그룹	자치구 수	비만율	총체육시설	배달비중	흡연율
영호(관리 우수)	7	24.8%	667	0.095	0.120
외식환경 취약(배달 과밀)	6	28.5%	625	0.126	0.121
시설 취약(인프라 부족)	12	28.5%	476	0.121	0.146

표 2. 군집별 프로파일

- 양호 그룹(7구):
강남·서초·마포·성동·영등포·용산·종로.
체육시설이 많고(667개) 배달 과밀도가
낮아 비만율이 가장 낮다(24.8%).
- 외식환경 취약 그룹(6구):
강동·구로·노원·동작·송파·양천.
체육시설은 충분(625개)하나 배달친화
점포비중이 12.6%로 가장 높다.
- 시설 취약 그룹(12구):
강북·강서·관악·광진·금천·도봉·동대문·
서대문·성북·은평·중구·중랑.
체육시설이 476개로 양호 그룹의 71%
수준이고 흡연율도 가장 높다.

정책 설계의 분기점은 여기에 있다. 외식환경
취약 그룹과 시설 취약 그룹은 비만율이
28.5%로 동일하지만 그 원인이
정반대다. 따라서 모든 자치구에 동일한
체육시설 확충을 적용하는 일률적 처방은
외식환경 취약 그룹에는 효과를 기대하기
어려우며, 군집별 차등 개입이 필요함을
시사한다.




그림 5 - [좌] 계층별 군집 덴드로그램 + [우]
정책그룹 산점도

VI. 회귀 분석 — 비만 결정요인 규명

6.1 선형 회귀 (개인 BMI, OLS, n=45,621)

연속형 BMI를 행동·인구 요인으로 설명하는
OLS 결과, 모든 계수가 통계적으로
유의했다(표
3). 연령(+0.070/년)·고스트레스(+0.40)·흡연(
+0.21)은 BMI를 끌어올리고,
여성(-3.08)·수면(-0.13/시간)은 낮춘다.

표 3. 개인 BMI 선형회귀 계수 (PART G · 셀 39)

변수	계수	p값
연령	+0.070	<0.001
여성	-3.085	<0.001
고스트레스	+0.397	<0.001
흡연	+0.207	<0.001
음주빈도	-0.027	0.010
수면	-0.134	<0.001

표 3. 개인 BMI 선형회귀 계수

본 모형의 결정계수는 $R^2=0.174$ 다. 결정계수가
높지 않은 것은 모형이 무의미하기 때문이
아니라 개인 단위 행동 데이터가 본질적으로
갖는 특성에서 비롯된다. 개인의 BMI는
유전·대사·식이처럼 설문으로 포착되지 않는
요인이 대부분을 설명하므로 행동변수 중심
회귀의 R^2 는 통상 0.1~0.3 수준에 머물며, 동일
데이터를 자치구 단위로 집계하면 생태학적
평화 효과로 R^2 가 0.45까지 상승한다(VIII장).
한편 F-검정의 유의확률이 0에 가깝고 모든
계수가 $p<0.05$ 로 유의하여 변수 간 관계 자체는
통계적으로 명확하며, 다중공선성 또한 전
변수의 VIF가 5 미만으로 문제되지 않는다.
무엇보다 본 분석의 목적은 BMI를 정밀하게
예측하는 데 있지 않고 비만의 위험요인과 정책
개입 지점을 규명하는 데 있으므로, 모형의
유효성은 결정계수가 아니라 분류 성능 지표인
AUC로 판단한다(VII장).

6.2 로지스틱 회귀

이진 결과(비만)에 대한 위험요인을 Odds
Ratio로 정량화하였다(Pseudo $R^2=0.099$, 그림
6). 고스트레스 OR 1.27, 흡연 OR 1.16은 비만
위험을 유의하게 높이고, 수면 OR
0.94(시간당), 여성 OR 0.225는 낮춘다.
음주빈도는 OR 0.99($p=0.082$)로 유의하지
않았다. 정책적으로 개입 가능한 지점은
스트레스·흡연·수면 세 가지로 압축된다.




그림 6. 비만 발생에 대한 위험요인별 오즈비(Odds Ratio)

VII. 예측·분류 모델 및 연관 분석

7.1 의사결정트리·랜덤포레스트·뉴럴네트워크

개인 비만 여부를 세 모델로 예측·비교하였다. 비만 클래스가 약 27%로 불균형하므로, 정확도보다 ROC-AUC를 주 비교지표로 삼았다(표 4, 그림 7). 세 모델의 AUC는 0.71~0.72로 유사했으며, 변수 중요도는 성별·연령 등 인구요인이 가장 컸고 흡연·수면·스트레스가 뒤를 이었다. 인구요인은 통제 대상이고, 행동요인이 정책 개입 지점이다.

표 4. 분류 모델 성능 비교 (PART I · 셀 47)

모델	Accuracy	ROC-AUC
의사결정트리	0.649	0.712
랜덤포레스트	0.653	0.716
뉴럴네트워크	0.734	0.717

표 4. 분류 모델 성능 비교




그림 7. [좌] 의사결정트리 + [중] 랜덤포레스트 변수 중요도 + [우] 모델별 ROC-AUC

7.2 연관 분석 — 위험요인 동시발생

흡연·고스트레스·우울·비만의 동시발생을 support/confidence/lift로 분석하였다(표 5, 그림 8). 우울→고스트레스(lift 2.37)가 가장 강하게 결합하고, 흡연→비만(lift 1.49), 흡연→우울(1.30), 고스트레스→흡연(1.20), 고스트레스→비만(1.08) 순으로 우연 이상의 동시발생을 보였다. 이는 위험요인들이 독립적으로 발생하지 않고 사슬(정신건강 → 흡연 → 비만)을 이룬다는 의미로, 단일 요인별 분절 서비스보다 통합 개입이 효과적임을 시사한다.

표 5. 연관규칙 (lift>1)

규칙(A→B)	support	confidence	lift
우울 → 고스트레스	0.052	0.719	2.37
흡연 → 비만	0.054	0.407	1.49
흡연 → 우울	0.012	0.094	1.30
고스트레스 → 흡연	0.048	0.159	1.20
고스트레스 → 비만	0.090	0.295	1.08

표 5. 연관규칙




그림 8. 위험요인 연관 규칙 lift 막대그래프

VIII. 자치구 수준 회귀 — H1/H2 검정

개인 모델과 별개로, 환경요인이 자치구 비만율을 직접 설명하는지 OLS로 검정하였다(n=25, 표 6).

$$\begin{aligned} \text{비만율} &= 16.75 + 103.23 \times \\ &\text{배달친화 점포비중} - 0.0021 \times \\ &\text{총체육시설수} \quad (R^2=0.453, \text{VIF}<5) \end{aligned}$$

표 6. 자치구 수준 회귀 (n=25, PART K · 셀 53)

변수	계수	p값	판정
배달친화 점포비중	+103.23	0.001	H1 지지
총체육시설수	-0.0021	0.182	H2 방향 일치(비유의)

표 6. 자치구 수준 회귀

배달친화 점포비중 계수 + 103.23은 $p=0.001$ 로 강하게 유의하다. 해석하면, 자치구의 배달친화 점포비중이 1%p 높아질 때 청년 비만율이 약 1.03%p 상승한다(0.01×103.23). 이는 H1을 강하게 지지한다. 총체육시설수 계수는 -0.0021로 방향은 H2와 일치하나 $p=0.182$ 로 통계적 유의성에는 이르지 못해 H2는 부분 지지로 판정한다. 자치구 횡단면 R²가 개인 모델(0.174)보다 높은 0.453인 것은 집계에 따른 생태학적 평활 효과로 해석된다.

IX. 결론 및 정책 제안

9.1 가설 검증 종합

가설 검증 종합

가설	결과	근거
H1 (배달환경 ↑ → 비만 ↑)	채택	상관 +0.637, 자치구회귀 $\beta=+103.23$ ($p=0.001$)
H2 (체육시설 ↑ → 비만 ↓)	부분 지지	상관 -0.323, 회귀 $\beta=-0.0021$ (방향 일치·비유의)
H3 (행동요인·동시발생)	채택	로지스틱 OR>1, 연관 $\text{lift}>1$

표 7. 가설검증 종합

9.2 핵심 발견

첫째, 자치구 청년 비만은 신체활동량보다 식이 환경에 더 강하게 규정된다. 걷기일수와 비만율의 상관은 -0.003으로 무관한 반면, 배달친화 점포비중은 +0.637로 가장 강했다. 둘째, 비만율이 같아도 동인은 다르다 — 외식환경 취약 6구와 시설 취약 12구는 동일한 28.5% 비만율에 도달했으나 원인 구조가 정반대다. 셋째, 개인 위험요인은 사슬로 동시발생한다(정신건강 → 흡연 → 비만). 넷째, 청년 비만은 성별 편중이 극심하다 — 남성

비만을 42.0% 대 여성 13.9%로 28.1%p 격차다.

9.3 정책 제안 (타겟 · 수단 · 기대효과)

가이드라인이 요구한 ‘구체적 수혜 대상과 기대 효과’에 부합하도록, 추상적 구호 대신 군집으로 식별한 자치구에 데이터로 검증된 수단을 매칭하였다.

제안 1 — 군집 차등형 ‘투-트랙’ 비만 대응 (동일 비만율, 상이한 처방) 일률적 개입을 폐기하고 군집별로 처방을 분리한다.

- **트랙 A(시설 취약 12구):** 체육시설이 양호 그룹의 71%(476개)에 불과하다. 고비용·장기인 신규 체육관 신축 대신, 학교운동장 야간·주말 개방과 공공청사 유휴공간의 청년 생활체육 거점화를 우선하고 청년 운동바우처(월정액)를 병행한다.

수혜 대상: 강북·금천·도봉·중랑 등 12개 자치구 거주 청년.

기대효과: 양호 그룹과의 비만율 격차 3.7%p의 단계적 축소.

- **트랙 B(외식환경 취약 6구):** 체육시설이 충분(625개)하므로 운동 인프라 추가는 효과가 낮다. 대신 배달밀집 상권의 식이 환경에 직접 개입한다 — 배달앱 연계 건강식 인센티브(저칼로리·균형식 메뉴 배달비 매칭 할인), 배달친화 상권 영양표시 강화.

근거: 자치구회귀 $\beta=103.23 \rightarrow$ 점포비중 1%p 감소 시 비만율 약 1.03%p 감소 기대.

주목할 근거는 다음과 같다. 양천구는 평균걷기일수 5.67일로 25개 자치구 중 최상위인데도 비만율 30.3%로 상위권이다 — 운동을 늘려도 식이 환경(배달비중 0.133)이 나쁘면 비만이 잡히지 않는다는 직접 증거다.

제안 2 — 위험요인 동시발생 차단형 ‘청년 통합 생활습관 클리닉’ (흡연을 비만 정책으로 편입)

연관분석은 흡연→비만(lift 1.49),
우울→고스트레스(lift 2.37),
고스트레스→비만(lift 1.08)의 사슬을
보여준다. 금연클리닉·정신건강센터·체중관리를
따로 운영하는 분절형 서비스는 이
동시발생군을 놓친다. 보건소 기존 인프라를
묶어 금연·수면/스트레스 코칭·체중관리를
하나의 패키지로 제공하고,
흡연·고스트레스·수면부족 중 2개 이상을
보유한 청년을 우선 등록 대상으로 선별한다.

수혜 대상: 복합 위험요인 보유 청년. **기대효과:**
단일 요인 개입의 누수 없이 위험 사슬 자체를
차단한다.

역설적이지만, 흡연 대책을 ‘금연 정책’이
아니라 ‘비만 정책’으로 재배치하는 접근이다.

**제안 3 — 성별·생애주기 가중 자원배분 (보편
캠페인에서 정밀 타겟으로)** 청년 비만은 사실상
남성 문제다(남성 42.0% vs 여성 13.9%,
선형회귀 여성계수 -3.08, 로지스틱 OR
0.225). 연령 OR도 1.04/년으로 30대의 누적
위험이 더 크다. 성별·연령 무차별 예산 배분은
비효율을 낳는다. 따라서 청년 비만 예산을
위험도 가중(남성·30대 우선)으로 재배분하고,
남성 청년 도달 채널(직장 건강검진 연계, 군
전역자 사후관리, 남성 다수 직군)을 확보한다.
기대효과: 동일 예산 대비 비만 위험 감소 효율
극대화.

9.4 정책 결정 대시보드

분석 결과를 정책 담당자가 상시 활용하도록,
군집·정책그룹이 결합된
master_clustered.csv를 입력으로 인터랙티브
대시보드를 구축하였다(그림 9). KPI는 청년
비만율(핵심 지표)과 회귀·상관에서 영향력이
큰 변수(배달진화
점포비중·총체육시설수·흡연율)로 선정하여,
자치구 필터링과 군집별 위험 진단을 한
화면에서 지원한다.

9.5 분석의 한계

① **연관 ≠ 인과** — 정책 수단의 인과효과는
향후 준실험(전후 비교·이중차분)으로 추가
검증해야 한다. ② **횡단면 통합** — 측정시점이
다른 데이터를 자치구별 다년 평균으로
통일하여 시점 변화가 일부 평활화되었다. ③
표본·통계력 — KCHS는 자기보고 설문이며,
자치구 n=25로 환경 회귀의 통계력이
제한적이다(H2의 비유의성도 부분적으로 이에
기인한다).

참고문헌 및 데이터 출처

1. 질병관리청, 「
지역사회건강조사(KCHS)」 원시
마이크로데이터, 2019~2025.
<https://chs.kdca.go.kr>
2. 서울 열린데이터광장, 「공공체육시설
통계」·「등록·신고 체육시설 통계」.
<https://data.seoul.go.kr>
3. 서울시 상권분석서비스, 「
점포·추정매출·상권영역」,
2021~2025.
<https://golmok.seoul.go.kr>
4. Scikit-learn / 5. Statsmodels
Documentation.

